


- C) Amazon DynamoDB
- D) AWS Lambda

Question 3 : Quel service AWS est recommandé pour visualiser des tableaux de bord interactifs basés sur les données d'un entrepôt de données ?

- A) Amazon RDS
- B) AWS Glue
- ☒ Amazon QuickSight
- D) Amazon Redshift Spectrum

1. Conception de l'Architecture



Justification des Choix

L'ingest des données provenant de plusieurs sources va se faire avec Amazon Kinesis Data Streams qui est un service spécialisé dans l'ingestion temps réel. Ensuite ces données sont stockées dans S3 comme un outil de stockage intermédiaire des données brutes, ensuite en utilisant Amazon Athena on va faire les analyses de ces données et ensuite les stocker dans le data warehouse Amazon Redshift et enfin la visualisation des données provenant de l'entrepôt des données va se faire en utilisant Amazon QuickSight.

AVIS IMPORTANT AUX ETUDIANTS

1. Chacune des feuilles de votre copie doit comporter une étiquette code à barres placée à l'endroit indiqué «coller ici votre code à barres».
2. Une copie d'examen comporte une seule «feuille principale» et des «feuilles suites». Sur chacune de vos feuilles, le code à barres est obligatoire.
3. Cette feuille d'examen est strictement personnelle. Elle ne doit comporter aucun signe distinctif. Elle doit être écrite en noir et/ou bleu.
4. Le non respect de l'une de ces recommandations peut faire attribuer la note ZERO à l'épreuve.

NOTE

15,5

00	01	02	03	04	05	06	07	08	09	10	11	12	13	14	15	16	17	18	19	20
															X					

00	25	50	75
		X	

Epreuve : Machine Learning et Bases massives MM

Classe : AIM

Enseignante : Asma BEN LETAIFA

Doc non autorisés

Octobre 2024

Nom, prénom et signature
de l'enseignant correcteur



Exercice 1

Étude de Cas 1	1. A	2. D	3. B
Étude de Cas 2	B	B	C

Étude de Cas 1 : Optimisation d'un Pipeline ETL pour une Société de Retail

Contexte : Une société de retail utilise un pipeline ETL pour extraire, transformer et charger des données de ventes, d'inventaire et de clients dans un entrepôt de données Amazon Redshift. Le pipeline est composé de plusieurs étapes : l'extraction des données depuis des bases de données SQL, la transformation des données en utilisant AWS Glue, et le chargement des données dans Redshift. Le processus est devenu lent, et les temps de traitement sont trop longs, ce qui affecte la mise à jour des rapports financiers et opérationnels.

Objectif : répondez d'abord à ces questions QCM puis Identifiez les problèmes dans le pipeline ETL existant et proposez des améliorations pour optimiser les performances.

Question 1 : Quel service AWS devrait être utilisé pour optimiser le traitement des données en batch dans AWS Glue afin de réduire le temps de traitement ?

- ☒ A) AWS Lambda
- ☐ B) Amazon EC2
- ☐ C) Amazon Redshift
- ☐ D) AWS Glue en mode Spark

Question 2 : Quelle configuration est recommandée pour améliorer les performances lors du chargement des données dans Amazon Redshift ?

- ☐ A) Utiliser des requêtes SQL ad-hoc pour les chargements de données
- ☐ B) Configurer les clés de distribution et de tri optimales pour les tables
- ☐ C) Exécuter les inserts ligne par ligne
- ☒ D) Utiliser le service AWS Athena pour le chargement des données

Question 3 : Quel service AWS est recommandé pour ingérer des données en temps réel dans un pipeline ETL ?

- ☐ A) Amazon RDS
- ☒ B) Amazon Kinesis Data Streams
- ☐ C) AWS CloudTrail
- ☐ D) Amazon S3

Solution Détaillée

1. Analyse des Problèmes

Le problème dans le pipeline existant c'est qu'il est un processus qui prend beaucoup de temps et qui nécessite ce qui est un inconvénient pour les entreprises et qui ralentit l'évolution des process au sein de l'entreprise

2. Propositions d'Amélioration

pour améliorer les performances de ce pipeline on peut remplacer le pipeline ETL traditionnel par un pipeline ETL qui suit les étapes suivantes : extraire les données, nettoyer les données le maximum possible, ensuite les charger dans Amazon Redshift ensuite faire le traitement sur l'ensemble des données qu'ils souhaitent traiter

Justification des Choix

Pour ce pipeline ETL, faciliter beaucoup le processus de traitement des données et optimiser les performances et de faire gagner beaucoup de temps. Surtout que le traitement va se faire sur l'ensemble de données que l'entreprise suggère.

Étude de Cas 2 : Mise en Place d'un Système de Data Warehouse pour une Plateforme de Streaming Vidéo

Contexte : Une plateforme de streaming vidéo souhaite mettre en place un système de data warehouse pour analyser les données des utilisateurs, les vidéos, et les performances du système en temps réel. Les données proviennent de plusieurs sources, y compris des logs de serveurs, des interactions des utilisateurs, et des métadonnées des vidéos. L'objectif est de consolider ces données dans un entrepôt de données pour exécuter des analyses avancées et générer des rapports en temps réel.

Objectif : Répondez à ces questions QCM puis Concevez une architecture pour cet entrepôt de données et proposez des solutions pour l'ingestion, le traitement, et l'analyse des données.

Question 1 : Quel service AWS devrait être utilisé pour effectuer des analyses ad-hoc sur les données stockées dans Amazon S3 ?

- ☐ A) Amazon QuickSight
- ☒ B) Amazon Athena
- ☒ C) AWS Glue
- ☐ D) Amazon Kinesis Data Firehose

Question 2 : Quel service AWS est le plus approprié pour stocker les résultats intermédiaires et les données brutes dans un système de data warehouse ?

- ☐ A) Amazon RDS
- ☒ B) Amazon S3



Exercice 2 Concevez une solution AWS pour chacun des scénarios suivants en répondant aux questions suivantes dans le tableau ci dessous. (4,5 points)

Scénario 1 : Ingestion et Traitement des Données en Temps Réel

Contexte : Une entreprise de streaming vidéo souhaite analyser les comportements des utilisateurs en temps réel pour améliorer les recommandations de contenu. Les données sur les vues des utilisateurs sont envoyées en continu et doivent être traitées pour mettre à jour les recommandations.

Question 1 : Quel service AWS permet d'ingérer des flux de données en temps réel et de les acheminer vers des destinations comme Amazon S3 ou Amazon Redshift ?

- ☒ a) Amazon Kinesis Data Firehose
- b) Amazon S3
- c) Amazon Athena
- d) Amazon RDS

Question 2 : Pour traiter les données en temps réel et exécuter des transformations complexes, quel framework de traitement distribué pouvez-vous utiliser sur AWS ?

- ☒ a) Amazon EMR
- b) AWS Glue
- c) Amazon Redshift
- d) Amazon RDS

Question 3 : Quelle est la meilleure façon d'assurer que les transformations des données en temps réel sont effectuées de manière fiable et scalable ?

- a) Utiliser Amazon S3 pour le stockage
- b) Déployer un cluster Apache Kafka
- ☒ c) Mettre en place des Lambda Functions pour le traitement des événements
- d) Configurer des instances EC2 pour le traitement manuel des données

Scénario 2 : Conception d'un Pipeline ETL

Contexte : Vous devez concevoir un pipeline ETL pour transférer des données de ventes de plusieurs systèmes source vers une base de données analytique afin de générer des rapports et des analyses.

Question 1 : Quel service AWS est le mieux adapté pour effectuer des transformations complexes et des chargements de données dans une base de données analytique ?

- ☒ a) AWS Glue
- b) Amazon CloudWatch
- c) AWS Data Pipeline
- d) Amazon RDS

Question 2 : Pour orchestrer un pipeline ETL complexe avec plusieurs étapes et dépendances, quel service AWS devriez-vous utiliser ?

- ☒ a) Amazon Step Functions
- b) Amazon Athena
- c) Amazon DynamoDB
- d) Amazon Aurora

Question 3 : Quelle approche utilisez-vous pour gérer les erreurs et les échecs dans un pipeline ETL sur AWS ?

- a) Ignorer les erreurs et continuer le traitement
- ☒ b) Configurer des alertes via Amazon CloudWatch et réessayer les tâches échouées
- c) Réinitialiser le pipeline et redémarrer le processus depuis le début
- d) Utiliser des scripts manuels pour corriger les erreurs

Scénario 3 : Optimisation de la Performance des Requêtes SQL

Contexte : Vous gérez un entrepôt de données dans Amazon Redshift et vous devez optimiser les performances des requêtes SQL pour des analyses complexes sur de grands volumes de données.

Question 1 : Quel mécanisme dans Amazon Redshift vous permet d'améliorer les performances des requêtes en distribuant les données sur plusieurs nœuds ?

- a) Distribution des données
- b) Indexation
- ☒ c) Partitions
- d) Caching

Question 2 : Pour analyser les performances des requêtes SQL et identifier les goulots d'étranglement dans Amazon Redshift, quel service devriez-vous utiliser ?

- a) Amazon CloudWatch
- b) Amazon QuickSight
- ☒ c) Amazon Redshift Console Query Performance
- d) AWS Glue Data Catalog

Question 3 : Quelle est la meilleure pratique pour optimiser les performances d'une table dans Amazon Redshift qui est fréquemment utilisée dans des requêtes analytiques complexes ?

- a) Utiliser des index
- b) Configurer des tables de jointure appropriées
- c) Utiliser la compression de données
- ☒ d) Créer des vues matérialisées

Scénario 1	1. A ✓	2. A ✓	3. c ✓
Scénario 2	1. A ✓	2. A ✓	3. B ✓
Scénario 3	1. c ✓	2. c ✓	3. d ✓

3,5



Exercice 3

Jeu de Rôle A : Optimisation d'un Pipeline de Données

Contexte : Vous êtes un ingénieur de données au sein d'une entreprise de médias en ligne qui rencontre des problèmes de performance avec son pipeline de données. Actuellement, les données des utilisateurs sont collectées en temps réel pour des analyses de comportement et de recommandations de contenu, mais le pipeline présente des goulots d'étranglement, ce qui entraîne des délais dans la mise à jour des recommandations. Le pipeline utilise Amazon Kinesis pour l'ingestion des données, AWS Lambda pour le traitement, et Amazon Redshift pour le stockage des données analytiques.

Instructions :

1. **Identifier les problèmes :** Examinez le pipeline actuel et identifiez les problèmes qui pourraient être à l'origine des lenteurs.
2. **Proposer des améliorations :** Suggérez des améliorations spécifiques pour résoudre ces problèmes de performance.
3. **Justifier vos choix :** Expliquez pourquoi les solutions proposées amélioreront la performance du pipeline.

1. Identifier les Problèmes

Utilisation de AWS Lambda pour le traitement des données est lente. Le pipeline est trop lent. Il y a des délais dans la mise à jour des recommandations. En plus, le fait de faire un pipeline qui fait l'ingestion, le traitement et le stockage prend beaucoup de temps.

2. Proposer des Améliorations

Stockage des données ingérées par Kinesis dans un Data Lake S3, ensuite faire le traitement avec AWS Lambda et ensuite faire le stockage dans Amazon Redshift.

3. Justifier les Choix

Le choix de cette architecture consiste à diminuer le temps de traitement des données qui est concentré juste sur le don d'un ensemble de données spécifique et non pas toutes les données.

Jeu de Rôle B : Mise en Place d'un Système de Monitoring et d'Alerting pour un Pipeline de Données

Contexte : Vous êtes ingénieur de données dans une entreprise de services financiers. Votre pipeline de données collecte des transactions financières en temps réel, les traite et les stocke dans une base

de données pour une analyse ultérieure. Cependant, vous avez constaté des incidents sporadiques dans le pipeline, et il est difficile de détecter et de réagir à ces incidents rapidement.

Instructions :

1. Concevez une solution de monitoring et d'alerting pour ce pipeline de données.
2. Proposez des outils et des configurations pour surveiller l'état du pipeline et alerter les équipes en cas de problèmes.

1. Conception de la Solution de Monitoring et d'Alerting

une des solutions de monitoring et d'alerting pour ce pipeline de données est de pouvoir gérer les erreurs et les tâches échouées en utilisant le service AWS qui est Amazon CloudWatch.

2. Justification des Choix

Amazon CloudWatch permet de gérer et surveiller l'état du pipeline à travers des alertes en cas de problème ou d'erreur.


Jeu de Rôle C : Conception d'un Système de Data Warehouse pour une Startup de Commerce Électronique

Contexte : Une startup de commerce électronique souhaite créer un entrepôt de données pour consolider les données provenant de plusieurs sources, telles que les ventes, les stocks et les interactions des utilisateurs, afin d'améliorer les analyses et les rapports. Vous êtes chargé de concevoir l'architecture de cet entrepôt de données sur AWS.

Instructions :

1. Proposez une architecture pour cet entrepôt de données en utilisant des services AWS.
2. Décrivez les choix de services pour chaque composant de l'architecture et justifiez vos choix.

1. Conception de l'Architecture de l'Entrepôt de Données



2. Justification des Choix

Pour le service d'ingestion de données on va utiliser Amazon Glue car il supporte l'ingestion de différents types de données provenant de plusieurs sources. Ensuite on va utiliser AWS crawler pour extraire le schéma des données et stocker les données dans Amazon Redshift qui est le data warehouse puisque ensuite on peut appliquer des requêtes à l'aide d'Athena.