




- C) Amazon DynamoDB
- D) AWS Lambda

Question 3 : Quel service AWS est recommandé pour visualiser des tableaux de bord interactifs basés sur les données d'un entrepôt de données ?

- A) Amazon RDS
- B) AWS Glue
- C) Amazon QuickSight
- D) Amazon Redshift Spectrum

1. Conception de l'Architecture process



Justification des Choix

- Amazon Kinesis Data Streams : pour l'ingestion des données en streaming
- Amazon Kinesis Data Firehose : pour transférer les données en Amazon S3
- Amazon EMR : pour le traitement de grands volumes de données
- Amazon QuickSight : pour visualiser des tableaux de bord interactifs

AVIS IMPORTANT AUX ETUDIANTS

- Chacune des feuilles de votre copie doit comporter une étiquette code à barres placée à l'endroit indiqué «coller ici votre code à barres».
- Une copie d'examen comporte une seule «feuille principale» et des «feuilles suites». Sur chacune de vos feuilles, le code à barres est obligatoire.
- Cette feuille d'examen est strictement personnelle. Elle ne doit comporter aucun signe distinctif. Elle doit être écrite en noir et/ou bleu.
- Le non respect de l'une de ces recommandations peut faire attribuer la note ZERO à l'épreuve.

NOTE

14/25



|    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |    |
|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|----|
| 00 | 01 | 02 | 03 | 04 | 05 | 06 | 07 | 08 | 09 | 10 | 11 | 12 | 13 | 14 | 15 | 16 | 17 | 18 | 19 | 20 | 00 | 25 | 50 | 75 |
|    |    |    |    |    |    |    |    |    |    |    |    |    |    | X  |    |    |    |    |    |    |    |    |    | X  |

Epreuve : Machine Learning et Bases massives MM

Classe : AIM

Enseignante : Asma BEN LETAIFA

Doc non autorisés

Octobre 2024

Nom, prénom et signature  
de l'enseignant correcteur



V1

666F

## Exercice 1

|                |   |   |   |   |   |    |
|----------------|---|---|---|---|---|----|
| Étude de Cas 1 | 1 | D | 2 | D | 3 | B  |
| Étude de Cas 2 |   | B | C |   |   | CL |

## Étude de Cas 1 : Optimisation d'un Pipeline ETL pour une Société de Retail

**Contexte :** Une société de retail utilise un pipeline ETL pour extraire, transformer et charger des données de ventes, d'inventaire et de clients dans un entrepôt de données Amazon Redshift. Le pipeline est composé de plusieurs étapes : l'extraction des données depuis des bases de données SQL, la transformation des données en utilisant AWS Glue, et le chargement des données dans Redshift. Le processus est devenu lent, et les temps de traitement sont trop longs, ce qui affecte la mise à jour des rapports financiers et opérationnels.

**Objectif :** répondez d'abord à ces questions QCM puis Identifiez les problèmes dans le pipeline ETL existant et proposez des améliorations pour optimiser les performances.

**Question 1 :** Quel service AWS devrait être utilisé pour optimiser le traitement des données en batch dans AWS Glue afin de réduire le temps de traitement ?

- A) AWS Lambda
- B) Amazon EC2
- C) Amazon Redshift
- D) AWS Glue en mode Spark

**Question 2 :** Quelle configuration est recommandée pour améliorer les performances lors du chargement des données dans Amazon Redshift ?

- A) Utiliser des requêtes SQL ad-hoc pour les chargements de données
- B) Configurer les clés de distribution et de tri optimales pour les tables
- C) Exécuter les inserts ligne par ligne
- D) Utiliser le service AWS Athena pour le chargement des données

**Question 3 :** Quel service AWS est recommandé pour ingérer des données en temps réel dans un pipeline ETL ?

- A) Amazon RDS
- B) Amazon Kinesis Data Streams
- C) AWS CloudTrail
- D) Amazon S3

## Solution Détaillée

## 1. Analyse des Problèmes

Cette société utilise un pipeline ETL très simple qui ne permet ni d'optimiser le traitement des données ni leur

chargement dans Amazon Redshift. Ils ne peuvent ingérer les données en temps réel et ils utilisent aucun service ce qui rend le processus très long.

## 2. Propositions d'Amélioration

Pour améliorer le pipeline, nous devons utiliser Spark pour l'ingestion de données en batch et Amazon Kinesis Data Streams pour les données en temps réel avec Amazon Kinesis Data Firehose pour le traitement de données nous pouvons utiliser Amazon EMR.

## Justification des Choix

Apache Spark : données en batch ; distribution des données  
Amazon Kinesis Data Streams : ingestion de données by stream  
Amazon Kinesis Data Firehose : transfert des données by stream à Amazon Redshift  
Amazon EMR : traitement des grands volumes de données  
Amazon QuickSight : visualisation et dashboards BI

## Étude de Cas 2 : Mise en Place d'un Système de Data Warehouse pour une Plateforme de Streaming Vidéo

**Contexte :** Une plateforme de streaming vidéo souhaite mettre en place un système de data warehouse pour analyser les données des utilisateurs, les vidéos, et les performances du système en temps réel. Les données proviennent de plusieurs sources, y compris des logs de serveurs, des interactions des utilisateurs, et des métadonnées des vidéos. L'objectif est de consolider ces données dans un entrepôt de données pour exécuter des analyses avancées et générer des rapports en temps réel.

**Objectif :** Répondez à ces questions QCM puis Concevez une architecture pour cet entrepôt de données et proposez des solutions pour l'ingestion, le traitement, et l'analyse des données.

**Question 1 :** Quel service AWS devrait être utilisé pour effectuer des analyses ad-hoc sur les données stockées dans Amazon S3 ?

- A) Amazon QuickSight
- B) Amazon Athena
- C) AWS Glue
- D) Amazon Kinesis Data Firehose

**Question 2 :** Quel service AWS est le plus approprié pour stocker les résultats intermédiaires et les données brutes dans un système de data warehouse ?

- A) Amazon RDS
- B) Amazon S3



**Exercice 2 Concevez une solution AWS pour chacun des scénarios suivants en répondant aux questions suivantes dans le tableau ci dessous. (4,5 points)**

**Scénario 1 : Ingestion et Traitement des Données en Temps Réel**

**Contexte :** Une entreprise de streaming vidéo souhaite analyser les comportements des utilisateurs en temps réel pour améliorer les recommandations de contenu. Les données sur les vues des utilisateurs sont envoyées en continu et doivent être traitées pour mettre à jour les recommandations.

**Question 1:** Quel service AWS permet d'ingérer des flux de données en temps réel et de les acheminer vers des destinations comme Amazon S3 ou Amazon Redshift ?

- a) Amazon Kinesis Data Firehose
- b) Amazon S3
- c) Amazon Athena
- d) Amazon RDS

**Question 2 :** Pour traiter les données en temps réel et exécuter des transformations complexes, quel framework de traitement distribué pouvez-vous utiliser sur AWS ?

- a) Amazon EMR
- b) AWS Glue
- c) Amazon Redshift
- d) Amazon RDS

**Question 3 :** Quelle est la meilleure façon d'assurer que les transformations des données en temps réel sont effectuées de manière fiable et scalable ?

- a) Utiliser Amazon S3 pour le stockage
- b) Déployer un cluster Apache Kafka
- c) Mettre en place des Lambda Functions pour le traitement des événements
- d) Configurer des instances EC2 pour le traitement manuel des données

**Scénario 2 : Conception d'un Pipeline ETL**

**Contexte :** Vous devez concevoir un pipeline ETL pour transférer des données de ventes de plusieurs systèmes source vers une base de données analytique afin de générer des rapports et des analyses.

**Question 1 :** Quel service AWS est le mieux adapté pour effectuer des transformations complexes et des chargements de données dans une base de données analytique ?

- a) AWS Glue
- b) Amazon CloudWatch
- c) AWS Data Pipeline
- d) Amazon RDS

**Question 2 :** Pour orchestrer un pipeline ETL complexe avec plusieurs étapes et dépendances, quel service AWS devriez-vous utiliser ?

- a) Amazon Step Functions
- b) Amazon Athena
- c) Amazon DynamoDB
- d) Amazon Aurora

**Question 3:** Quelle approche utilisez-vous pour gérer les erreurs et les échecs dans un pipeline ETL sur AWS ?

- a) Ignorer les erreurs et continuer le traitement
- b) Configurer des alertes via Amazon CloudWatch et réessayer les tâches échouées
- c) Réinitialiser le pipeline et redémarrer le processus depuis le début
- d) Utiliser des scripts manuels pour corriger les erreurs

**Scénario 3 : Optimisation de la Performance des Requêtes SQL**

**Contexte :** Vous gérez un entrepôt de données dans Amazon Redshift et vous devez optimiser les performances des requêtes SQL pour des analyses complexes sur de grands volumes de données.

**Question 1 :** Quel mécanisme dans Amazon Redshift vous permet d'améliorer les performances des requêtes en distribuant les données sur plusieurs nœuds ?

- a) Distribution des données
- b) Indexation
- c) Partitions
- d) Caching

**Question 2 :** Pour analyser les performances des requêtes SQL et identifier les goulets d'étranglement dans Amazon Redshift, quel service devriez-vous utiliser ?

- a) Amazon CloudWatch
- b) Amazon QuickSight
- c) Amazon Redshift Console Query Performance
- d) AWS Glue Data Catalog

**Question 3 :** Quelle est la meilleure pratique pour optimiser les performances d'une table dans Amazon Redshift qui est fréquemment utilisée dans des requêtes analytiques complexes ?

- a) Utiliser des index
- b) Configurer des tables de jointure appropriées
- c) Utiliser la compression de données
- d) Créer des vues matérialisées

|            |      |      |      |
|------------|------|------|------|
| Scénario 1 | 1. a | 2. a | 3. b |
| Scénario 2 | 1. a | 2. a | 3. b |
| Scénario 3 | 1. c | 2. d | 3. a |

25



V2

888F

## Exercice 3

## Jeu de Rôle A : Optimisation d'un Pipeline de Données

**Contexte :** Vous êtes un ingénieur de données au sein d'une entreprise de médias en ligne qui rencontre des problèmes de performance avec son pipeline de données. Actuellement, les données des utilisateurs sont collectées en temps réel pour des analyses de comportement et de recommandations de contenu, mais le pipeline présente des goulots d'étranglement, ce qui entraîne des délais dans la mise à jour des recommandations. Le pipeline utilise Amazon Kinesis pour l'ingestion des données, AWS Lambda pour le traitement, et Amazon Redshift pour le stockage des données analytiques.

## Instructions :

1. **Identifier les problèmes :** Examinez le pipeline actuel et identifiez les problèmes qui pourraient être à l'origine des lenteurs.
2. **Proposer des améliorations :** Suggérez des améliorations spécifiques pour résoudre ces problèmes de performance.
3. **Justifier vos choix :** Expliquez pourquoi les solutions proposées amélioreront la performance du pipeline.

## 1. Identifier les Problèmes

Le pipeline ETL manque les services AWS intermédiaires qui facilitent les étapes de l'ingestion au traitement. Il manque aussi la partie visualisation des données. AWS du pipeline n'est pas automatisé (CI/CD)

## 2. Proposer des Améliorations

On peut aboutir à une IAC l'infrastructure as a code, on ajoute la part de visualisation avec des dashboards interactifs. On peut aussi ajouter AWS Glue. On peut changer le service de traitement par Amazon EMR, c'est plus performant

## 3. Justifier les Choix

• AWS Cloud Formation : A l'aide d'une template on peut aboutir à une infrastructure programmée  
• AWS Quickstart & Dashboards BI  
• AWS Glue : ETL automatique  
• AWS EMR : c'est performant au niveau de grands volumes de données

## Jeu de Rôle B : Mise en Place d'un Système de Monitoring et d'Alerting pour un Pipeline de Données

**Contexte :** Vous êtes ingénieur de données dans une entreprise de services financiers. Votre pipeline de données collecte des transactions financières en temps réel, les traite et les stocke dans une base

- AWS Lake Formation: pour faciliter le traitement de données en Data Lake
- Amazon OpenSearch: pour l'analyse de données in near real-time

de données pour une analyse ultérieure. Cependant, vous avez constaté des incidents sporadiques dans le pipeline, et il est difficile de détecter et de réagir à ces incidents rapidement.

## Instructions :

1. Concevez une solution de monitoring et d'alerting pour ce pipeline de données.
2. Proposez des outils et des configurations pour surveiller l'état du pipeline et alerter les équipes en cas de problèmes.

## 1. Conception de la Solution de Monitoring et d'Alerting

Pour détecter et réagir à des incidents rapidement, on doit concevoir une solution de logging et une solution de monitoring et d'alerting

## 2. Justification des Choix

Amazon CloudTrail : collecte les logs, l'analyse et permet de détecter les incidents  
Amazon CloudWatch : cette solution permet de surveiller les performances et même d'envoyer des alertes en cas d'urgence


## Jeu de Rôle C : Conception d'un Système de Data Warehouse pour une Startup de Commerce Électronique

**Contexte :** Une startup de commerce électronique souhaite créer un entrepôt de données pour consolider les données provenant de plusieurs sources, telles que les ventes, les stocks et les interactions des utilisateurs, afin d'améliorer les analyses et les rapports. Vous êtes chargé de concevoir l'architecture de cet entrepôt de données sur AWS.

## Instructions :

1. Proposez une architecture pour cet entrepôt de données en utilisant des services AWS.
2. Décrivez les choix de services pour chaque composant de l'architecture et justifiez vos choix.

## 1. Conception de l'Architecture de l'Entrepôt de Données



## 2. Justification des Choix

• Amazon Flink : traitement distribué de données  
• Amazon Redshift : Data Warehouse pour le stockage des données  
• AWS Glue : pour générer les schémas  
• AWS Glue Catalog : pour visualiser les schémas générés  
• Amazon QuickSight : pour générer les dashboards BI  
• Amazon Kinesis : pour l'ingestion de données en streaming  
• Amazon S3 : Data Lake